

# 通常最小二乗法 (Ordinary Least Squares: OLS)

T.Chiba

2020 年 5 月 24 日

## 概要

最小二乗法についてみていく.

## 1 最小二乗法 (1 変量)

本題に入る前に, リハビリもかねて 1 変量の最小二乗法を確認する. 線形回帰モデルは下記のような構造をしていると考えられる.

$$y = \alpha + \beta x + \varepsilon \quad (1)$$

$x, y$  についての観測値  $\{(x_i, y_i) | i = 1, 2, \dots, n\}$  がそれぞれ次のような構造を持っていると仮定する.

$$y_i = \alpha + \beta x_i + \varepsilon_i, i = 1, \dots, n \quad (2)$$

誤差  $\varepsilon$  の平方和を考える.

$$Q(\alpha, \beta) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n \{y_i - (\alpha + \beta x_i)\}^2 \quad (3)$$

これを, 偏差平方和と呼ぶ. $Q(\alpha, \beta)$  を最小にするような  $\alpha = \hat{\alpha}, \beta = \hat{\beta}$  を最小二乗推定量 (Least Squares Estimator: LSE) と呼ぶ.

$$\begin{cases} \frac{\partial Q(\alpha, \beta)}{\partial \alpha} = 0 \\ \frac{\partial Q(\alpha, \beta)}{\partial \beta} = 0 \end{cases} \quad (4)$$

を満たすような  $\alpha, \beta$  を考える. 2 階の偏微分まで計算すると,

$$\frac{\partial Q}{\partial \alpha} = -2 \sum_{i=1}^n (y_i - \alpha - \beta x_i) \quad (5)$$

$$\frac{\partial^2 Q}{\partial \alpha^2} = 2n > 0 \quad (6)$$

$$\frac{\partial Q}{\partial \beta} = -2 \sum_{i=1}^n x_i (y_i - \alpha - \beta x_i) \quad (7)$$

$$\frac{\partial^2 Q}{\partial \beta^2} = 2 \sum_{i=1}^n x_i^2 > 0 \quad (8)$$

$$\frac{\partial^2 Q}{\partial \alpha \partial \beta} = 0 \quad (9)$$

ヘッセ行列は,

$$H = \begin{bmatrix} \frac{\partial^2 Q}{\partial \alpha^2} & \frac{\partial^2 Q}{\partial \alpha \partial \beta} \\ \frac{\partial^2 Q}{\partial \alpha \partial \beta} & \frac{\partial^2 Q}{\partial \beta^2} \end{bmatrix} = \begin{bmatrix} 2n & 0 \\ 0 & 2 \sum x_i^2 \end{bmatrix} \quad (10)$$

いま, 任意の 2 次元ベクトル  $\mathbf{t} = (t_1, t_2)'$  に対して二次形式,

$$\mathbf{t}' H \mathbf{t} = (t_1, t_2) \begin{pmatrix} 2n & 0 \\ 0 & 2 \sum x_i^2 \end{pmatrix} \begin{pmatrix} t_1 \\ t_2 \end{pmatrix} = 2 \left( n t_1^2 + t_2^2 \sum x_i^2 \right) \geq 0 \quad (11)$$

となり,これが0となるのは, $t=0$ のときのみ. よってヘッセ行列  $H$  は正定値. つまり, 式 (4) を満たす,  $\alpha, \beta$  が極小値であることが分かる. また, 図1の形から, 極小かつ最小であることも分かる.




図1 2変数関数の二次関数のイメージ

式 (4) を解いていく.

$$\begin{cases} \frac{\partial Q}{\partial \alpha} = -2 \sum (y_i - \alpha - \beta x_i) = -2 \{ \sum y_i - n\alpha - \beta \sum x_i \} = 0 \\ \frac{\partial Q}{\partial \beta} = -2 \sum_{i=1}^n x_i (y_i - \alpha - \beta x_i) = -2 \{ \sum x_i y_i - \alpha \sum x_i - \beta \sum x_i^2 \} = 0 \end{cases} \quad (12)$$

$$\Leftrightarrow \begin{cases} \alpha n + \beta \sum x_i = \sum y_i \\ \alpha \sum x_i + \beta \sum x_i^2 = \sum x_i y_i \end{cases} \quad (13)$$

## 付録 A

### A.1 2変数関数の極値

偏差平方和を最小にするような,  $\alpha$  と  $\beta$  を求める際に,  $\alpha, \beta$  に関する偏微分を0として, 推定量を求めた. しかし, 偏微分が0と置くだけでは,  $Q(\alpha, \beta)$  の極値が求められるだけで, 最小値かどうかは分からない. テキストだと当たり前のようには書かれているけど.

#### A.1.1 極大・極小

関数  $f(x, y)$  は連続かつ微分可能とする.

**補題** 境界点<sup>\*1</sup>でない極大点, 極小点においては

$$\frac{\partial f}{\partial x}(x_0, y_0) = 0, \frac{\partial f}{\partial y}(x_0, y_0) = 0 \quad (14)$$

となる.

---

<sup>\*1</sup> [5] p18 参照.

証明 もし  $\frac{\partial f}{\partial x}(x_0, y_0) \neq 0$  ならば、微分可能性の定義<sup>\*2</sup>

$$\begin{cases} f(x, y) - f(x_0, y_0) = \frac{\partial f}{\partial x}(x_0, y_0)(x - x_0) + \frac{\partial f}{\partial y}(x_0, y_0)(y - y_0) + g(x, y), \\ \lim_{\mathbf{x} \rightarrow \mathbf{x}_0} \frac{g(\mathbf{x}, \mathbf{y})}{|\mathbf{x} - \mathbf{x}_0|} = 0 \end{cases}$$

において,  $y = y_0$  と置くと,

$$\begin{aligned} f(x, y_0) - f(x_0, y_0) &= \frac{\partial f}{\partial x}(x_0, y_0)(x - x_0) + g(x, y_0) \\ &= \frac{\partial f}{\partial x}(x_0, y_0)(x - x_0) \left\{ 1 + c \cdot \frac{g(x, y_0)}{x - x_0} \right\} \end{aligned}$$

右辺の  $\{ \}$  の中は  $x$  が  $x_0$  に十分近いとき  $> 0$  となる. 一方,  $x - x_0$  は  $x$  が  $x_0$  の近傍を動く時必ず符号を変えるため,  $f(x_0, y_0)$  は極大値でも極小値でもないことが分かる.  $\frac{\partial f}{\partial y}(x_0, y_0) \neq 0$  としても同様.

これにより, 連立方程式

$$\frac{\partial f}{\partial x}(x_0, y_0) = 0, \frac{\partial f}{\partial y}(x_0, y_0) = 0$$

を解けば, 境界点でない極値の候補者が全て見つかる. □

### A.1.2 極大・極小の判定

極大値か極小値かの判定はヘッセ行列により行うことができる.

定義 (ヘッセ行列) 行列

$$\begin{bmatrix} f_{xx} & f_{xy} \\ f_{xy} & f_{yy} \end{bmatrix}$$

を  $f(x, y)$  に関するヘッセ行列という.

定理  $\frac{\partial f}{\partial x}(x_0, y_0) = \frac{\partial f}{\partial y}(x_0, y_0) = 0$  を満たす点  $x_0, y_0$  においてヘッセ行列が<sup>\*3</sup>

正定値  $(x_0, y_0)$  は極小値

負定値  $(x_0, y_0)$  は極大値

不定値  $(x_0, y_0)$  は極値点ではない

### A.1.3 正定値・負定値・不定値

$\mathbf{x}'\mathbf{A}\mathbf{x}$  を任意の二次形式とする. ただし,  $\mathbf{x} = (x_1, \dots, x_n)'$ .

非負定値 (nonnegative definite)  $\mathcal{R}^n$ <sup>\*4</sup>のあらゆる  $\mathbf{x}$  に対して  $\mathbf{x}'\mathbf{A}\mathbf{x} \geq 0$  であるとき.  $\mathbf{x}$  の少なくとも 1 つの値, 具体的には  $\mathbf{x} = \mathbf{0}$  に対して,  $\mathbf{x}'\mathbf{A}\mathbf{x} = 0$  であることに注意.

正定値 (positive definite)  $\mathbf{x}'\mathbf{A}\mathbf{x}$  が非負定値かつ, 零ベクトル  $\mathbf{0}$  に対してのみ  $\mathbf{x}'\mathbf{A}\mathbf{x} = 0$  となる時. すなわち,  $\mathbf{x} = \mathbf{0}$  を除く, あらゆる  $\mathbf{x}$  に対して  $\mathbf{x}'\mathbf{A}\mathbf{x} > 0$  のとき.

半正定値 (positive semidefinite) 非負定値であるが, 正定値でない二次形式. あらゆる  $\mathbf{x} \in \mathcal{R}^n$  に対して,  $\mathbf{x}'\mathbf{A}\mathbf{x} \geq 0$  で, ある  $\mathbf{x} \neq \mathbf{0}$  に対して  $\mathbf{x}'\mathbf{A}\mathbf{x} = 0$  のとき.

非正定値, 負定値, 半負定値 それぞれ,  $-\mathbf{x}'\mathbf{A}\mathbf{x}$  が, 非負定値, 正定値, 半正定値のとき.

<sup>\*2</sup>  $z = f(x, y)$  が点  $\mathbf{x}_0 = (x_0, y_0)$  で微分可能であるとは, ある定数  $\alpha, \beta$  があって,

$$\begin{cases} f(x, y) = f(x_0, y_0) + \alpha(x - x_0) + \beta(y - y_0) + g(x, y) \\ \lim_{\mathbf{x} \rightarrow \mathbf{x}_0} \frac{g(\mathbf{x}, \mathbf{y})}{|\mathbf{x} - \mathbf{x}_0|} = 0 \end{cases} \quad (\mathbf{x} = (x, y) \neq \mathbf{x}_0)$$

と表せること ([5] p153 参照)

<sup>\*3</sup> 高校数学の美しい物語とか参考になる: <https://mathtrain.jp/hessian>

不定値 (indefinite) 非負定値でも, 非正定値でもない二次形式.

## 参考文献

- [1] Tze Leung Lai, Haipeng Xing 著, 松原 望, 山村吉信 訳: 『ファイナンスのための統計学 -統計的アプローチによる評価と意思決定-』, 東京図書, 2016
- [2] 鈴木 武, 山田 作太郎: 『数理統計学 -基礎から学ぶデータ解析』, 内田老鶴圃, 1996
- [3] 稲垣宣生: 『数学シリーズ 数理統計学 (改訂版)』, 裳華房, 2003
- [4] 江川博康: 『弱点克服 大学生の微積分』 東京図書, 2005
- [5] 笠原皓司: 『サイエンスライブラリー 数学=12 微分積分学』, サイエンス社, 1974
- [6] David A. Harville, (監訳) 伊里正夫: 『統計のための行列代数 (上)』, 丸善出版, 2016

---

\*4 記号  $\mathcal{R}^{m \times n}$  はその要素が全ての  $m \times n$  行列からなる線形空間を表す. 記号  $\mathcal{R}^n$  は全ての  $n$  列次元ベクトルの集合.